

**UNIVERSIDADE NOVE DE JULHO – UNINOVE**  
**DIRETORIA DE INFORMÁTICA**



***PROJETO DE INTELIGÊNCIA ARTIFICIAL E***  
***APRENDIZADO DE MÁQUINAS***

***Sistema de Detecção de Lixo em Tempo Real para***  
***Cidades Inteligentes via Câmeras Públicas***

**SÃO PAULO**  
**2025**

# **Projeto de Inteligência Artificial e Aprendizado de Máquinas**

## **Sistema de Detecção de Lixo em Tempo Real para Cidades Inteligentes via Câmeras Públicas**

|                            |              |
|----------------------------|--------------|
| VITOR HUGO DA SILVA SANTOS | RA:625102765 |
| RIVO PAMPLONA              | RA:624204861 |
| THIAGO SERAFIM             | RA:625105078 |
| VICTOR MACENA              | RA:625102836 |
| RAFAEL MACENO              | RA:625104325 |

Trabalho apresentado ao curso de Pós-Graduação Latu Sensu – Inteligência Artificial e Aprendizado de Máquinas da Universidade Nove de Julho, como parte dos requisitos para a obtenção do Grau de Especialista em Inteligência Artificial e Aprendizado de Máquinas.

Orientadores: **Prof. Dr. Ivanir Costa** e  
**Prof. Dr. Peterson Belan**

Unidade: Campus: MM

Curso: Pós-Graduação Latu Sensu  
Inteligência Artificial e  
Aprendizado de Máquinas

Período: Primeiro Semestre - 2025

São Paulo  
2025

## RESUMO

O presente projeto propõe o desenvolvimento de um sistema de detecção automática de resíduos sólidos urbanos em tempo real, utilizando algoritmos de Inteligência Artificial aplicados a imagens captadas por câmeras públicas instaladas em áreas urbanas.

A iniciativa visa contribuir com a automação dos serviços de limpeza pública, otimizando a alocação de recursos e promovendo maior eficiência na gestão de resíduos em ambientes urbanos. A metodologia envolve a coleta de imagens, treinamento de modelos de *Deep Learning* e integração com sistemas de notificação para envio de alertas às equipes responsáveis.

Espera-se como resultado a construção de um protótipo funcional, capaz de detectar diferentes tipos de lixo com alta precisão, fornecendo dados úteis para o planejamento urbano e contribuindo para a sustentabilidade e qualidade de vida nas cidades inteligentes.

Palavras-chave: Cidades Inteligentes. Detecção de Lixo. Inteligência Artificial. Limpeza Urbana. Visão Computacional.

## ABSTRACT

This project proposes the development of a real-time automatic detection system for urban solid waste using Artificial Intelligence algorithms applied to images captured by public cameras installed in urban areas. The initiative aims to support the automation of public cleaning services by optimizing resource allocation and promoting greater efficiency in waste management within urban environments. The methodology involves image collection, training of Deep Learning models, and integration with notification systems to send alerts to responsible teams. The expected outcome is the construction of a functional prototype capable of detecting different types of waste with high accuracy, providing valuable data for urban planning and contributing to sustainability and quality of life in smart cities.

Keywords: Smart Cities, Waste Detection, Artificial Intelligence, Urban Cleaning, Computer Vision.

## **Lista de Tabelas**

|          |    |
|----------|----|
| Tabela 1 | 19 |
| Tabela 2 | 22 |

# Sumário

|                                                  |    |
|--------------------------------------------------|----|
| Capítulo 1 – <b>INTRODUÇÃO</b>                   | 8  |
| 1.1 Contextualização                             | 8  |
| 1.2 Objetivo Geral                               | 9  |
| 1.3 Relevância                                   | 9  |
| Capítulo 2 – <b>FUNDAMENTAÇÃO TEÓRICA</b>        | 10 |
| 2.1 Panorama                                     | 12 |
| 2.2 Revisão da Literatura                        | 15 |
| 2.3 Conexão                                      | 16 |
| Capítulo 3 – <b>METODOLOGIA</b>                  | 17 |
| 3.1 Abordagem Metodológica                       | 17 |
| 3.2 Ferramentas e Tecnologias usadas             | 18 |
| 3.3 Cronograma de Execução                       | 21 |
| 3.4 Tabela 1 – Cronograma de Execução do Projeto | 23 |
| Capítulo 4 – <b>DESENVOLVIMENTO</b>              | 24 |
| 4.1 Impactos da Implementação                    | 24 |
| 4.2 4 Plano de Ação                              | 24 |
| 4.3 4 Execução na Prática                        | 26 |
| Capítulo 5 – <b>RESULTADOS E DISCUSSÕES</b>      | 28 |
| 5.1 Achados                                      | 29 |
| 5.2 Impactos na Prática                          | 29 |
| 5.3 Reflexões                                    | 30 |
| Capítulo 6 – <b>CONCLUSÃO</b>                    | 31 |
| 6.1 Considerações Finais                         | 32 |
| <b>7. REFERÊNCIAS BIBLIOGRÁFICAS</b>             | 33 |

# **1 Introdução**

## **1.1 Contextualização**

O desenvolvimento e a adoção de tecnologias digitais têm proporcionado transformações significativas na gestão pública, sobretudo no contexto urbano. Cidades que almejam alcançar o status de cidades inteligentes vêm investindo em soluções tecnológicas para otimizar seus serviços e promover a sustentabilidade. Dentre essas soluções, destacam-se os sistemas de monitoramento e análise em tempo real que, aliados à Inteligência Artificial (IA) e à visão computacional, possibilitam novas formas de abordagem para problemas antigos, como o descarte inadequado de resíduos sólidos em vias públicas.

A crescente urbanização tem intensificado os desafios relacionados à limpeza urbana, exigindo das administrações públicas uma resposta mais rápida, eficaz e econômica. Nesse cenário, o uso de câmeras públicas integradas a algoritmos de detecção automática de lixo representa uma inovação promissora. Esses sistemas permitem que a presença de resíduos em locais públicos seja identificada de forma imediata, possibilitando o acionamento automatizado de equipes de limpeza, a priorização de áreas críticas e o acompanhamento contínuo da situação ambiental urbana.

Além de aprimorar a eficiência operacional dos serviços de limpeza, essas tecnologias contribuem significativamente para a formulação de políticas públicas baseadas em evidências. A coleta sistemática de dados sobre a distribuição geográfica e temporal dos resíduos sólidos permite às gestões municipais não apenas reagir aos problemas, mas também antecipá-los por meio de análises preditivas. Com isso, torna-se viável o planejamento de intervenções mais estratégicas, a alocação inteligente de recursos e a definição de campanhas educativas voltadas às regiões com maior incidência de descarte irregular.

Ademais, a integração dessas ferramentas com plataformas de governança digital favorece a transparência e a participação cidadã, na medida em que os dados coletados podem ser disponibilizados em tempo real para a população, estimulando o engajamento social e a corresponsabilidade na preservação dos espaços urbanos. Essa abordagem multidimensional, que combina inovação tecnológica, sustentabilidade ambiental e gestão participativa, alinha-se aos princípios fundamentais do conceito de

cidade inteligente, promovendo uma urbanização mais resiliente, inclusiva e orientada por dados.

Nesse contexto, a adoção de sistemas de visão computacional aplicados à gestão de resíduos sólidos urbanos não apenas representa um avanço técnico, mas também um passo decisivo rumo a uma administração pública mais responsiva, sustentável e alinhada às demandas contemporâneas das cidades em processo de transformação digital.

## **1.2 Objetivo Geral**

Este projeto tem como objetivo central desenvolver um sistema de detecção automática de resíduos sólidos urbanos em tempo real, utilizando algoritmos de inteligência artificial aplicados a imagens capturadas por câmeras públicas instaladas em áreas urbanas. O propósito é automatizar e otimizar o gerenciamento de limpeza urbana, oferecendo suporte tecnológico à tomada de decisão em ambientes classificados como cidades inteligentes.

## **1.3 Relevância**

A proposta possui elevada relevância social, ambiental e tecnológica, pois oferece uma abordagem inovadora para a gestão do lixo urbano. Os principais benefícios práticos esperados incluem:

- Melhoria da eficiência operacional na coleta e remoção de resíduos;
- Redução de custos relacionados à alocação inadequada de recursos de limpeza;
- Resposta ágil a situações críticas, como acúmulo excessivo de lixo em locais estratégicos;
- Geração de dados para análise preditiva, contribuindo com o planejamento de políticas públicas urbanas;
- Melhoria na qualidade de vida da população, por meio de ambientes urbanos mais limpos e saudáveis.

Além disso, espera-se o desenvolvimento de um protótipo funcional com alta taxa de acurácia na detecção de resíduos, capaz de integrar-se a plataformas de monitoramento urbano já existentes. Essa solução pode servir como modelo replicável para diversas cidades que desejam implementar ações sustentáveis por meio da transformação digital de seus serviços públicos.

## 2 Fundamentação Teórica

### 2.1 Panorama

A fundamentação teórica deste sistema está focada em três pilares principais: cidades inteligentes, visão computacional aplicada à detecção de objetos e gestão sustentável de resíduos sólidos urbanos.

#### **Cidades Inteligentes (*Smart Cities*):**

O conceito de cidades inteligentes (*Smart Cities*) envolve a integração de tecnologias da informação e comunicação (TIC) com o ambiente urbano, visando aumentar a eficiência dos serviços, melhorar a qualidade de vida da população e promover a sustentabilidade. O surgimento das cidades inteligentes está diretamente relacionado ao crescimento populacional e à necessidade de gerir de forma eficiente os recursos urbanos limitados. Diversos elementos compõem uma cidade inteligente, incluindo mobilidade urbana inteligente, energia renovável, segurança pública, gestão eficiente de água e resíduos, bem como a integração de dispositivos conectados à Internet das Coisas (IoT).

Dentro do contexto das cidades inteligentes, a coleta e o gerenciamento de dados são essenciais para a tomada de decisão em tempo real. Tecnologias como big data, computação em nuvem e redes 5G permitem que informações sobre trânsito, consumo de energia, níveis de poluição e gestão de resíduos sejam continuamente monitoradas e analisadas. Essa capacidade de resposta rápida e baseada em dados contribui para tornar a gestão urbana mais eficiente e adaptável às necessidades da população.

Os benefícios das cidades inteligentes incluem a otimização dos serviços públicos, a redução de custos operacionais, a melhora da mobilidade urbana, a minimização dos impactos ambientais e o aumento da segurança. No entanto, a implementação efetiva das *Smart Cities* também enfrenta desafios significativos, como a necessidade de infraestrutura adequada, investimento em tecnologia, integração de diferentes sistemas e preocupações com privacidade e segurança de dados.



O sistema se insere nesse cenário ao propor um sistema automatizado de detecção de resíduos sólidos em vias urbanas, utilizando tecnologias emergentes como visão computacional e inteligência artificial. Ao permitir o monitoramento em tempo real da ocorrência de lixo nas ruas, o sistema contribui diretamente para a gestão eficiente dos resíduos e para a melhoria da qualidade ambiental nas cidades (Nunes, 2025).

## **1. Definição e Evolução Histórica**

- Conceito de cidades inteligentes: da teoria à prática (Gibson et al., 1992; Harrison & Donnelly, 2011).
- Cronologia: desde as primeiras iniciativas (Songdo, Coreia do Sul) até modelos contemporâneos (Barcelona, Singapura).
- Critérios da ISO 37120 para cidades sustentáveis.

## **2. Pilares das *Smart Cities***

- Infraestrutura Tecnológica: IoT, 5G, sensores urbanos.
- Governança e Participação Cidadã: Plataformas digitais de engajamento (ex.: Decidim Barcelona).
- Mobilidade Inteligente: Sistemas de transporte integrado (ex.: Curitiba - RIT).
- Energia e Sustentabilidade: Microgrids e energia renovável (ex.: Masdar, Emirados Árabes).

## **3. Tecnologias Habilitadoras**

- Big Data Analytics: Otimização de tráfego (ex.: IBM Intelligent Operations Center).
- IA na Gestão Urbana: Predição de demandas (ex.: Algoritmos para alocação de lixeiras em Tóquio).
- Blockchain para transparência (ex.: Dubai Blockchain Strategy).

## **4. Desafios e Críticas**

- Privacidade de dados (GDPR e LGPD).
- Exclusão digital e desigualdades (estudo de caso: Rio de Janeiro - Morro da Providência vs. Porto Maravilha).

- Custos de implementação (análise de ROI em projetos europeus).

### **Visão Computacional e *Deep Learning*:**

A visão computacional, um ramo da inteligência artificial, capacita máquinas a interpretar e compreender imagens e vídeos de forma semelhante aos humanos. Esse campo tem avançado significativamente com o *deep learning*, especialmente as redes neurais convolucionais (CNNs), que são altamente eficazes na detecção e classificação de objetos em imagens. As CNNs, com suas camadas convolucionais, extraem características hierárquicas das imagens para identificar padrões visuais complexos.

Modelos como YOLO (You Only Look Once) e Faster R-CNN são amplamente empregados em aplicações que exigem detecção rápida e precisa de objetos em tempo real. O YOLO, por exemplo, realiza a detecção e classificação em uma única passagem da imagem pela rede, tornando-o ideal para cenários urbanos dinâmicos onde a resposta em tempo real é crucial (AGUIAR, 2024).

### **Aplicações em Cidades Inteligentes**

A visão computacional é aplicada em diversos setores de cidades inteligentes, incluindo vigilância, gestão de trânsito e monitoramento ambiental. Mais recentemente, seu uso se estendeu à gestão de resíduos sólidos. A capacidade de detectar automaticamente a presença de lixo em imagens capturadas por câmeras permite acionar os serviços de limpeza urbana de forma mais eficiente, reduzindo o tempo de resposta e prevenindo o acúmulo de resíduos.

A precisão desses modelos de *deep learning* na detecção de objetos pode ser aprimorada por meio de treinamento com grandes volumes de dados rotulados. Isso permite à rede aprender a distinguir entre diferentes tipos de resíduos, suas cores, tamanhos e formatos, viabilizando a categorização automática dos resíduos. Essa capacidade pode ser integrada a outros sistemas de gestão urbana para otimizar a coleta seletiva e promover a reciclagem.

No contexto de projetos, a aplicação da visão computacional na detecção de lixo visa contribuir para um ambiente urbano mais limpo e saudável, integrando-se a iniciativas de cidades inteligentes e apoiando a gestão eficiente dos serviços públicos. (R.C.Silva; T.A.Souza; Evelin H.S.C; Jasmine P.L.A, 2024).

## **Gestão Sustentável de Resíduos Sólidos:**

A gestão de resíduos sólidos tornou-se um dos maiores desafios ambientais e urbanos do século XXI, especialmente em países em desenvolvimento como o Brasil, onde a geração de lixo cresce anualmente em ritmo superior ao da capacidade de tratamento. Segundo a Associação Brasileira de Empresas de Limpeza Pública e Resíduos Especiais (ABRELPE, 2023), cada brasileiro produz, em média, 1,04 kg de resíduos por dia, totalizando 82 milhões de toneladas anuais – das quais apenas 4% são efetivamente recicladas. Esse cenário exige soluções urgentes, combinando avanços tecnológicos, marco regulatório eficiente e participação social.

A Política Nacional de Resíduos Sólidos (PNRS), instituída pela Lei nº 12.305/2010, representa o principal instrumento legal para enfrentar esse desafio. Ela estabelece a responsabilidade compartilhada entre fabricantes, distribuidores, consumidores e poder público, além de exigir a eliminação de lixões até 2024 – meta ainda distante, já que 40% dos municípios brasileiros ainda utilizam destinos inadequados. Um dos pilares da PNRS é a logística reversa, que obriga setores como eletroeletrônicos, pilhas e pneus a recolherem produtos pós-consumo. Por exemplo, desde 2022, fabricantes de eletrônicos devem estruturar pontos de coleta em parceria com prefeituras, sob risco de multas. Outro avanço foi a hierarquização de prioridades: não geração, redução, reutilização, reciclagem e, por fim, disposição final ambientalmente adequada.

No entanto, a implementação dessas diretrizes esbarra em obstáculos estruturais. A falta de recursos financeiros de municípios pequenos impede a adoção de tecnologias de ponta, como sensores IoT para monitoramento de lixeiras inteligentes. Além disso, a carência de educação ambiental dificulta a adesão à coleta seletiva: apenas 27% das cidades brasileiras possuem programas consolidados, segundo o Sistema Nacional de Informações sobre Saneamento (SNIS, 2022). Para superar essas barreiras, experiências internacionais oferecem insights valiosos. Em Cingapura, por exemplo, o sistema Pay-as-You-Throw (PAYT) cobra taxas diferenciadas conforme o volume de lixo gerado por residências, reduzindo em 22% os resíduos em aterros. Já na Alemanha, o DSD (Sistema Dual de Logística Reversa) garante que 90% das embalagens sejam recicladas, com custos compartilhados por empresas.

Nesse contexto, a tecnologia surge como aliada crítica. Soluções baseadas em inteligência artificial (IA) e visão computacional estão revolucionando a gestão de resíduos. Na cidade de Rotterdam (Holanda), câmeras acopladas a caminhões de lixo identificam, em tempo real, resíduos mal separados usando algoritmos de deep learning, notificando os moradores via aplicativo. No Brasil, startups como a Ciclo Orgânico (RJ) utilizam georreferenciamento para otimizar rotas de coleta de orgânicos, reduzindo em 30% os custos com combustível. Outro exemplo é o projeto Recicla Tech, desenvolvido pela USP, que emprega robôs com sensores infravermelhos para classificar plásticos por tipo (PET, PP, PEAD), aumentando a pureza dos fardos vendidos para indústrias.

A economia circular amplifica esses benefícios. Diferentemente do modelo linear (extrair-produzir-descartar), ela propõe um ciclo fechado onde resíduos viram insumos. A indústria têxtil é emblemática: a marca Malha, de São Paulo, transforma retalhos de jeans em novas peças, enquanto a Braskem desenvolveu um processo para converter garrafas PET em resina de poliéster, usada em móveis. No setor de construção civil, o entulho – que representa 50% dos resíduos urbanos – é triturado e transformado em agregados para pavimentação, seguindo a norma ABNT NBR 15.116. Essas iniciativas não só reduzem impactos ambientais, mas geram emprego: cooperativas como a Coopamare (SP) faturam R\$2,5 milhões/ano com a venda de materiais recicláveis.

Entretanto, persistem desafios complexos. A falta de padronização na coleta seletiva entre municípios dificulta a logística reversa. Enquanto Curitiba separa resíduos em 5 categorias, cidades como o Rio de Janeiro ainda misturam recicláveis e orgânicos. Outro entrave é o custo da tecnologia: um sistema de visão computacional para caminhões de lixo pode custar R\$150 mil por unidade – inviável para cidades com menos de 50 mil habitantes. Soluções incluem parcerias público-privadas (PPPs), como o modelo adotado em Belo Horizonte, onde a prefeitura compartilha os gastos com empresas de limpeza urbana.

Para um avanço sustentável, é essencial integrar políticas públicas, inovação e engajamento comunitário. Campanhas como Separe o Lixo e Acerte na Lata (MG) mostraram que a educação ambiental aumenta em 40% a adesão à coleta seletiva quando associada a incentivos fiscais. Simultaneamente, universidades e centros de pesquisa devem fomentar o desenvolvimento de tecnologias acessíveis, como o

BioDigester da Embrapa, que transforma restos de feiras livres em biogás para escolas rurais.

Em síntese, a gestão sustentável de resíduos sólidos demanda uma abordagem multidimensional. A combinação entre regulamentação rigorosa (como a PNRS), ferramentas tecnológicas (IA, IoT) e modelos econômicos circulares pode transformar o lixo em recurso, alinhando-se aos Objetivos de Desenvolvimento Sustentável (ODS) da ONU. O caso de San Francisco (EUA), que desviou 80% de seus resíduos de aterros através de metas progressivas e multas por descarte incorreto, prova que a mudança é viável – mas exige vontade política, investimento contínuo e participação ativa da sociedade.

O Sistema proposto alinha tecnologia de ponta às necessidades urbanas, contribuindo para os objetivos da PNRS, promovendo sustentabilidade e melhoria da qualidade de vida nas cidades.

## **2.2 Revisão da Literatura**

Diversos estudos demonstram a viabilidade e os benefícios da aplicação de IA na gestão de resíduos urbanos;

**Impacto Ambiental do Descarte Inadequado de Lixo:**

Para Kaline Ribeiro Figueiredo (2023), o descarte inadequado de lixo é um problema ambiental e social grave que afeta o Brasil. O país gera cerca de 80 milhões de toneladas de resíduos sólidos por ano, dos quais apenas 10% são reciclados. O descarte inadequado pode causar uma série de impactos negativos, como poluição do solo, da água e do ar, proliferação de vetores de doenças, e danos à saúde humana e ao meio ambiente.

**Estudos em Detecção Automatizada de Lixo:**

Pesquisas como a de Herath, H. M. K. K. M. B., & Mittal, M. (2022) mostram que modelos de *Deep Learning* alcançam a maioria dos setores com muita eficiência no seu uso em áreas urbanas.

**Impacto na Eficiência Operacional:**

Dados do Banco Mundial (2018) indicam que cidades que implementaram sistemas automatizados de gestão de resíduos reduziram custos operacionais em até 30%, além de aumentar a velocidade de resposta a pontos críticos de acúmulo de lixo.

## 2.3 Conexão

A fundamentação teórica sustenta a viabilidade do projeto, estabelecendo uma ligação direta entre os conceitos estudados e a aplicação prática:

Integração com Infraestrutura Existente:

A utilização de câmeras públicas já instaladas reduz custos de implementação, alinhando-se ao conceito de *Smart Cities* ao aproveitar recursos disponíveis.

Seleção de Algoritmos de IA:

Baseado na revisão bibliográfica, opta-se por modelos como YOLOv8 ou *EfficientDet*, que equilibram alta precisão e processamento em tempo real, essenciais para a detecção imediata de resíduos.

Impacto na Gestão Urbana:

- A automatização do processo permite:
- Alertas em tempo real para equipes de limpeza,
- Análise de dados históricos para identificar padrões de descarte irregular, apoiando políticas públicas (ex.: campanhas de conscientização em áreas críticas).

Conclusão da Fundamentação Teórica

O embasamento teórico apresentado reforça a originalidade e relevância do projeto, mostrando que a combinação de visão computacional, IA e gestão urbana pode trazer soluções inovadoras para um problema persistente. A revisão da literatura justifica a necessidade do sistema proposto, enquanto a conexão teórico-prática valida sua aplicabilidade em cenários reais de cidades inteligentes.

### **3. Capítulo – Metodologia**

#### **3.1 Abordagem Metodológica**

A abordagem metodológica adotada neste trabalho é fundamentada no desenvolvimento de uma solução tecnológica baseada em visão computacional e inteligência artificial, com aplicação em cidades inteligentes. Especificamente, optou-se por uma abordagem de estudo de caso aplicado, onde um protótipo funcional será desenvolvido e testado em um ambiente urbano real, utilizando imagens captadas por câmeras públicas instaladas em pontos estratégicos da cidade. Essa metodologia permite a validação prática do sistema em situações reais de uso, promovendo uma análise mais precisa da viabilidade e eficácia da proposta.

Inicialmente, a metodologia contempla uma revisão sistemática da literatura e dos sistemas existentes, buscando identificar os principais desafios na detecção automática de lixo em ambientes urbanos, as tecnologias atualmente utilizadas, e os algoritmos mais eficazes para esse tipo de tarefa. Essa etapa é essencial para embasar tecnicamente a escolha das ferramentas e técnicas utilizadas, bem como para justificar a necessidade de uma solução adaptada à realidade brasileira.

Em seguida, será realizada a coleta de dados, com foco na curadoria e anotação de imagens que representem diferentes tipos de resíduos sólidos em ambientes públicos, tais como ruas, calçadas, praças e áreas próximas a lixeiras e pontos de descarte. A base de dados será construída a partir de fontes públicas e registros próprios captados por câmeras, garantindo diversidade de cenários e condições de iluminação. O processo de anotação será feito utilizando ferramentas específicas, como Roboflow e LabelImg, com o objetivo de gerar dados rotulados compatíveis com algoritmos de aprendizado profundo.

A etapa subsequente envolve o treinamento e a avaliação de modelos de detecção de objetos baseados em redes neurais convolucionais, notadamente o modelo YOLOv8, que se destaca por sua alta precisão e desempenho em tempo real. Serão conduzidos testes iterativos com diferentes configurações de hiperparâmetros e métricas de avaliação, como precisão (precision), revocação (recall) e média de precisão média (mAP), a fim de determinar o melhor modelo para a tarefa proposta.

Posteriormente, será desenvolvido um protótipo funcional que integra o modelo treinado a uma API REST, permitindo que imagens captadas por câmeras públicas sejam processadas em tempo real. Essa API será hospedada em ambiente de nuvem (AWS EC2), garantindo escalabilidade e acesso remoto. Além disso, serão implementados mecanismos de armazenamento de metadados e visualização de dados em dashboards, com o auxílio de ferramentas como PostgreSQL, Grafana e Prometheus.

Por fim, a solução será implantada em um ambiente piloto real, onde será monitorado seu desempenho, tempo de resposta, e taxa de detecção de resíduos. Essa etapa visa validar a efetividade do sistema na prática, levantar dados para análise de impacto e propor melhorias com base no feedback do ambiente operacional. Todo o processo será documentado e os resultados serão discutidos à luz dos objetivos iniciais do projeto e dos benefícios para a gestão urbana inteligente.

### **3.2 Ferramentas e Tecnologias Utilizadas**

A escolha das ferramentas e tecnologias utilizadas neste projeto foi baseada em critérios como robustez, suporte da comunidade, compatibilidade com visão computacional e inteligência artificial, além da facilidade de integração em ambientes de produção. A seguir, descreve-se detalhadamente cada uma das tecnologias adotadas, justificando sua utilização:

**Python:** Linguagem de programação principal utilizada no projeto. Sua escolha se deve à ampla adoção na área de ciência de dados e inteligência artificial, bem como à vasta disponibilidade de bibliotecas especializadas. Python oferece facilidade de leitura, grande comunidade de suporte e integração direta com frameworks como PyTorch e OpenCV.

**OpenCV (Open Source Computer Vision Library):** Biblioteca de visão computacional de código aberto amplamente utilizada para processamento de imagens. É responsável por operações como leitura de vídeos das câmeras, tratamento de imagens, conversão de cores, detecção de movimento e manipulação de contornos. Sua eficiência e flexibilidade justificam seu uso na etapa de pré-processamento dos dados visuais.



YOLOv8 (You Only Look Once, versão 8): Framework de detecção de objetos em tempo real baseado em redes neurais convolucionais. Desenvolvido pela Ultralytics, o YOLOv8 é conhecido por sua precisão e velocidade, tornando-se ideal para aplicações em tempo real, como a detecção de lixo em vídeo. Será usado para treinar e aplicar modelos de detecção em imagens urbanas.

PyTorch: Biblioteca de aprendizado profundo utilizada para treinar os modelos de detecção. Foi escolhida por sua flexibilidade, eficiência e integração nativa com o YOLOv8. Além disso, seu paradigma dinâmico facilita o desenvolvimento e depuração de modelos.

Flask / FastAPI: Frameworks web em Python usados para criar APIs REST. Estas interfaces permitem que o modelo de IA seja acessado remotamente por outras aplicações ou dashboards. O FastAPI, em particular, foi escolhido por sua alta performance e suporte a tipagem, ideal para aplicações que exigem resposta em tempo real.

PostgreSQL: Banco de dados relacional utilizado para armazenar metadados das detecções, como localização, data, hora e tipo de lixo detectado. Foi escolhido por sua robustez, escalabilidade e suporte a consultas geoespaciais.

AWS EC2 (Amazon Web Services – Elastic Compute Cloud): Plataforma de nuvem utilizada para hospedar a aplicação. A escolha da AWS se deve à sua confiabilidade, escalabilidade e suporte a instâncias com aceleração por GPU, necessárias para inferência em tempo real.

Google Colab: Ferramenta utilizada durante a fase de prototipagem e treinamento preliminar dos modelos. Permite o uso gratuito de GPUs e fácil compartilhamento de notebooks.

OpenLitterMap e TACO Dataset: Bases de dados públicas com imagens anotadas de lixo em ambientes urbanos. Foram utilizadas como base para o treinamento dos modelos, complementadas por imagens captadas manualmente no cenário de estudo. A diversidade de classes e anotações detalhadas justificam seu uso.

Roboflow e LabelImg: Ferramentas de anotação de imagens usadas para marcar os resíduos sólidos nas imagens de treinamento. O Roboflow também oferece serviços de conversão de formato e aumento de dados (data augmentation), essenciais para melhorar a generalização do modelo.

Grafana + Prometheus: Ferramentas de monitoramento utilizadas para visualizar o desempenho do sistema em tempo real. Permitem o acompanhamento de métricas como tempo de resposta, número de detecções por hora e estado das câmeras integradas ao sistema.

Git + GitHub: Sistema de controle de versão utilizado para registrar o histórico de desenvolvimento do código-fonte, facilitando a colaboração e o gerenciamento das diferentes versões do projeto. GitHub também serve como repositório central e permite integração com pipelines de CI/CD.

| Categoria                | Tecnologia / Ferramenta                                  |
|--------------------------|----------------------------------------------------------|
| Linguagem de Programação | Python                                                   |
| Framework de Visão       | OpenCV, YOLOv8 (Ultralytics)                             |
| IA / Deep Learning       | PyTorch                                                  |
| Interface de Comunicação | Flask / FastAPI para endpoints REST                      |
| Banco de Dados           | PostgreSQL (armazenamento de metadados de detecção)      |
| Infraestrutura           | Google Colab (prototipagem), AWS EC2 (execução em nuvem) |
| Dataset                  | Dataset próprio + OpenLitterMap + TACO Dataset           |
| Ferramentas de Rotulagem | Roboflow, LabelImg                                       |
| Monitoramento e Logs     | Grafana + Prometheus (em ambiente de produção)           |
| Versionamento            | Git + GitHub                                             |

### 3.3 Cronograma de Execução

O cronograma de execução do projeto foi estruturado em sete etapas principais, cada uma com objetivos específicos e duração estimada. A divisão temporal permite o planejamento adequado dos recursos e a organização das atividades para garantir o cumprimento dos prazos estabelecidos. A seguir, descrevem-se as fases do cronograma, com suas respectivas funções dentro do desenvolvimento da solução de detecção de lixo em tempo real para cidades inteligentes:

#### **1. Levantamento de requisitos e revisão teórica (Semanas 1 a 2):**

Esta fase inicial consiste na análise bibliográfica e na pesquisa de soluções existentes. Busca-se compreender o estado da arte das tecnologias aplicadas à detecção de resíduos sólidos, especialmente em contextos urbanos. Também são definidos os requisitos técnicos e funcionais do sistema, bem como o escopo da solução proposta. Esta etapa é essencial para embasar teoricamente e orientar todas as fases subsequentes do projeto.

#### **2. Coleta e preparação de dados (Semanas 3 a 5):**

Durante essa etapa, são reunidas imagens provenientes de bases públicas (como o TACO Dataset e OpenLitterMap) e imagens captadas por câmeras urbanas. As imagens são rotuladas com ferramentas como Roboflow e LabelImg, sendo divididas em conjuntos de treino, validação e teste. O tratamento dos dados inclui normalização, redimensionamento e, quando necessário, técnicas de aumento de dados (data augmentation). Esta preparação garante que o modelo seja treinado com dados consistentes e representativos da realidade urbana.

#### **3. Treinamento e avaliação do modelo (Semanas 6 a 8):**

Nesta fase, o modelo de detecção de objetos YOLOv8 é treinado utilizando a biblioteca PyTorch. São aplicados diferentes experimentos com ajustes de hiperparâmetros e análise das métricas de desempenho, como precisão, revocação e mAP. Essa etapa é iterativa e exige ajustes finos no modelo até que se obtenha um nível de acurácia satisfatório para a aplicação proposta.

#### **4. Desenvolvimento do protótipo (Semanas 9 a 10):**

Com o modelo treinado, inicia-se o desenvolvimento do sistema que o tornará acessível por meio de uma API. Usando FastAPI ou Flask, cria-se uma interface que recebe imagens ou vídeos e retorna os resultados da detecção. O backend se comunica

com um banco de dados PostgreSQL que registra os metadados das detecções. Esta etapa também contempla a criação de um sistema de armazenamento e uma estrutura para hospedagem em nuvem (AWS EC2).

**5. Testes em ambiente simulado (Semanas 11 a 12):**

Nesta etapa, o sistema é testado com imagens e vídeos urbanos em um ambiente de simulação, recriando condições reais como variações de iluminação, movimentação de objetos e ruídos visuais. O objetivo é verificar a robustez e a velocidade da detecção em tempo real, identificando falhas e realizando os ajustes necessários.

**6. Validação em campo (Semanas 13 a 14):**

Após a validação em ambiente simulado, o sistema é implantado em um local real, utilizando câmeras públicas urbanas. Essa fase permite a coleta de dados operacionais em tempo real, sob condições reais de uso. O desempenho do sistema é acompanhado continuamente, e eventuais melhorias são implementadas com base nos dados coletados e no feedback da operação.

**7. Análise de resultados e conclusão (Semana 15):**

Por fim, os resultados obtidos durante a fase de testes e validação são organizados e analisados. São gerados gráficos, relatórios de desempenho e conclusões sobre a eficácia da solução. Esta fase também contempla a escrita do relatório final e a apresentação dos principais achados, lições aprendidas e possibilidades de melhorias futuras.

### 3.4 Tabela 1 – Cronograma de Execução do Projeto (Semanal)

| <b>Etapa</b>                                    | <b>S1</b> | <b>S2</b> | <b>S3</b> | <b>S4</b> | <b>S5</b> | <b>S6</b> | <b>S7</b> | <b>S8</b> | <b>S9</b> | <b>S10</b> | <b>S11</b> | <b>S12</b> | <b>S13</b> | <b>S14</b> | <b>S15</b> |
|-------------------------------------------------|-----------|-----------|-----------|-----------|-----------|-----------|-----------|-----------|-----------|------------|------------|------------|------------|------------|------------|
| 1. Levantamento de requisitos e revisão teórica | X         | X         |           |           |           |           |           |           |           |            |            |            |            |            |            |
| 2. Coleta e preparação de dados                 |           |           | X         | X         | X         |           |           |           |           |            |            |            |            |            |            |
| 3. Treinamento e avaliação do modelo            |           |           |           |           |           | X         | X         | X         |           |            |            |            |            |            |            |
| 4. Desenvolvimento do protótipo                 |           |           |           |           |           |           |           |           | X         | X          |            |            |            |            |            |
| 5. Testes em ambiente simulado                  |           |           |           |           |           |           |           |           |           |            | X          | X          |            |            |            |
| 6. Validação em campo                           |           |           |           |           |           |           |           |           |           |            |            |            | X          | X          |            |
| 7. Análise de resultados e conclusão            |           |           |           |           |           |           |           |           |           |            |            |            |            |            | X          |

## 4. Capítulo Desenvolvimento

### 4.1 Impactos da Implementação

Com base nas atividades destacadas até o momento, é possível pontuar os seguintes impactos:

- **Prototipagem Funcional que possa Alcançar Sucesso:**  
Espera-se que o sistema seja capaz de detectar lixo com acurácia superior a 88%, mesmo em condições de iluminação adversas.
- **Tempo de Resposta Eficiente:**  
A expectativa é que o tempo médio de inferência do modelo fique em torno de 1,7 segundos por imagem, permitindo atuação quase em tempo real.
- **Mapeamento Geográfico de Resíduos:**  
Pretende-se que as detecções sejam armazenadas com metadados (local, hora, tipo de resíduo), permitindo análises temporais e espaciais sobre o descarte irregular.
- **Potencial de Economia Operacional:**  
Estima-se que o uso do sistema possa reduzir em até 30% os custos com deslocamentos não planejados de equipes de limpeza, com base em projeções do Banco Mundial (2018).
- **Base para Ações Estratégicas:**  
O cruzamento de dados com regiões de baixa adesão à coleta seletiva permite que prefeituras direcionem campanhas educativas para bairros com maior incidência de lixo.

### 4.2 Plano de Ação

O desenvolvimento do projeto foi estruturado de acordo com o cronograma previamente definido, seguindo etapas progressivas em contemplar desde a coleta de dados até a implantação do sistema em ambiente real. O plano de ação adotado permite que seja válido cada fase do sistema de forma modular e incremental, garantindo a confiabilidade dos resultados.

As principais etapas que representam o caminho esperado em um possível desenvolvimento prático são:

1. **Levantamento de Requisitos e Revisão Teórica (Semanas 1–2)**
  - Análise da literatura sobre visão computacional, cidades inteligentes e gestão de resíduos sólidos.
  - Definição dos requisitos técnicos e funcionais do sistema, incluindo métricas de desempenho (acurácia mínima de 85%, detecção em tempo real).
2. **Coleta e Preparação de Dados (Semanas 3–5)**
  - Obtenção de imagens públicas (TACO Dataset, OpenLitterMap) e captura manual em cenários urbanos reais.
  - Anotação com ferramentas (Roboflow e LabelImg), categorizando resíduos por tipo (plástico, papel, orgânicos etc.).
  - Pré-processamento: redimensionamento, normalização, balanceamento e aplicação de técnicas de data augmentation.
3. **Treinamento e Avaliação dos Modelos (Semanas 6–8)**
  - Configuração do modelo YOLOv8 no Google Colab com suporte a GPU.
  - Execução de múltiplos ciclos de treinamento com ajustes nos hiperparâmetros (learning rate, número de epochs, batch size).
  - Avaliação utilizando métricas como mAP, precisão e recall.
4. **Desenvolvimento do Protótipo (Semanas 9–10)**
  - Criação da API REST com FastAPI, integrando o modelo de IA.
  - Integração com banco de dados PostgreSQL para registrar metadados das detecções.
  - Implantação em ambiente em nuvem (AWS EC2).
5. **Testes em Ambiente Simulado (Semanas 11–12)**
  - Simulação de cenários urbanos variados com vídeos e imagens captadas por câmeras públicas.
  - Avaliação do tempo de resposta, taxa de detecção, robustez frente a ruídos visuais.
6. **Validação em Campo (Semanas 13–14)**
  - Instalação do sistema em três câmeras da zona leste de São Paulo.
  - Monitoramento em tempo real com detecção automatizada durante cinco dias consecutivos.
  - Coleta de feedback de operadores e análise de desempenho prático.

## 7. **Análise Final e Consolidação (Semana 15)**

- Organização dos dados obtidos, análise de acertos e falhas, proposição de melhorias.
- Escrita do relatório final e elaboração dos materiais de apresentação.

### 4.3 **Execução Prática**

Com base em metodologias similares à execução prática, as atividades devem seguir o plano definido, com alguns ajustes e aprendizados relevantes:

- Coleta de Imagens:

As câmeras utilizadas para teste preveem captura de imagens em diferentes condições (dia, noite, chuva, sombras). O que enriquecerá a base de dados e permitirá treinar o modelo com maior diversidade visual. Um dos principais desafios estimados é eliminar imagens redundantes e identificar manualmente os resíduos com precisão.

- Treinamento do Modelo:

O modelo YOLOv8 deve ser treinado utilizando um conjunto de dados balanceado com cerca de 5.000 imagens. A proposta prevê múltiplas rodadas de treinamento com avaliação contínua de métricas como mAP, precisão e recall, realizando ajustes de hiperparâmetros para minimizar o overfitting.

O maior desafio será encontrar o equilíbrio entre velocidade de inferência e precisão – especialmente em ambientes com muitos elementos visuais (veículos, pedestres, sombras).

- Desenvolvimento da API:

A API FastAPI funcionará como intermediária entre o modelo treinado e o front-end de visualização. Pretende-se implementados endpoints para envio de imagens, consulta a registros anteriores e visualização de estatísticas. O sistema foi projetado para receber imagens em tempo real via stream das câmeras públicas.



- Implantação na Nuvem:

A proposta prevê a implantação do sistema em ambiente de nuvem, como a AWS EC2, com instâncias otimizadas para GPU. Antecipam-se desafios relacionados ao uso intensivo de recursos computacionais, sendo necessária a otimização do código para manter o tempo de inferência dentro do limite operacional de 2 segundos por imagem.

- Testes de Robustez:

Sugere-se submeter o sistema a vídeos simulados contendo ruídos visuais (ex: vento movimentando folhas, sacolas plásticas em movimento, reflexos). A expectativa é identificar possíveis falsos positivos e aperfeiçoar o modelo por meio de reanotação de imagens problemáticas e ajustes no dataset. A curadoria contínua da base será essencial para manter a precisão e robustez do sistema em situações reais.

## 5. Resultados e Discussão

### 5.1 Achados

A implementação e validação do sistema de detecção automática de lixo urbano em tempo real prevê uma série de resultados significativos, tanto no desempenho técnico quanto na aplicabilidade prática da solução proposta. Com base nisso, podemos esperar pelos seguintes resultados a serem obtidos:

#### 1. Alto Desempenho do Modelo de Detecção:

O modelo YOLOv8, ao ser treinado com mais de 5.000 imagens anotadas, pode alcançar os seguintes resultados:

- mAP (mean Average Precision): 88,3%
- Precisão (Precision): 91,4%
- Revocação (Recall): 85,7%

Esses valores são baseados em benchmarks disponíveis na literatura e sugerem uma performance satisfatória para aplicações urbanas em tempo real e em ambientes urbanos complexos.

#### 2. Velocidade de Inferência:

Prevê-se que o tempo médio de resposta por imagem processada fique em torno de 1,7 segundos, permitindo atuação quase imediata por parte das equipes de limpeza.

#### 3. Capacidade de Generalização:

A proposta considera que o sistema poderá identificar resíduos sólidos em diferentes contextos urbanos, como vias com sombra, áreas arborizadas e entornos de lixeiras, mesmo com grande variação visual no ambiente.

#### 4. Baixo Índice de Falsos Positivos:

Com ajustes adequados e expansão do conjunto de dados, a expectativa é que a taxa de falsos positivos fique abaixo de 9%, melhorando a distinção entre resíduos e outros elementos como folhas, papelão molhado ou sacolas vazias.

## 5. Geração de Dados Operacionais:

O sistema pode ser capaz de registrar automaticamente data, hora, localização e tipo de lixo detectado, resultando em um banco de dados georreferenciado. Isso viabilizará análises preditivas e geração de relatórios com indicadores urbanos.

### 5.2 Impactos na Prática

A aplicação na prática do sistema é de se esperar por diversos impactos positivos que venha demonstrar diversos benefícios potenciais para a gestão urbana:

#### 1. Eficiência Operacional:

A automatização da detecção poderá otimizar o deslocamento das equipes de limpeza, acionando-as apenas quando houver necessidade real. De acordo com estimativas do Banco Mundial (2018), isso pode representar até 30% de economia em custos com rotas não planejadas.

#### 2. Resposta em Tempo Real:

A rápida identificação de pontos com lixo acumulado permitirá reduzir o tempo médio de resposta das equipes de limpeza em aproximadamente 40%, mitigando de problemas como mau cheiro, proliferação de vetores e obstrução de vias públicas.

#### 3. Planejamento Estratégico com Base em Dados:

A análise de padrões temporais e espaciais de descarte irregular poderá subsidiar campanhas de educação ambiental, além da reconfiguração de rotas e instalação de lixeiras em locais estratégicos.

#### 4. Transparência e Governança Digital:

A arquitetura do sistema pode permitir a integração com plataformas abertas de dados, ampliando a transparência da gestão pública e possibilitando que a população acompanhe indicadores de limpeza urbana em tempo real, incentivando a corresponsabilidade social.

#### 5. Potencial de Escalabilidade:

Considerando o uso de infraestrutura já existente (como câmeras públicas) e tecnologias de código aberto, a solução poderá ser replicada em diferentes cidades, inclusive em municípios de médio porte, com orçamento limitado.

### 5.3 Reflexões

Durante a elaboração do projeto e sistema, algumas considerações importantes foram levantadas

- A Qualidade dos Dados é Decisiva:

A proposta reforça que a curadoria dos dados e a diversidade visual das imagens serão fundamentais para o desempenho do modelo de IA.

- Desafios com Condições Ambientais Variáveis:

Ambientes com pouca luz, presença de chuva ou sombra intensa podem representar um desafio, sendo necessário ampliar a base de dados com imagens em condições adversas e explorar técnicas de aumento de dados (data augmentation).

- Integração com Outras Tecnologias:

A junção do sistema de visão computacional com sensores IoT (ex.: lixeiras inteligentes com sensores de nível) e dispositivos robóticos (ex.: coletores autônomos) pode levar a soluções ainda mais completas e robustas.

- Educação Ambiental como Complemento:

Espera-se que os dados gerados pelo sistema sirvam também para fomentar campanhas educativas, voltadas a regiões com alta reincidência de descarte.

- Potencial de Expansão para Novos Cenários:

O sistema poderá ser adaptado para monitorar praias, parques, rodovias, zonas rurais ou eventos públicos, desde que os modelos sejam treinados com imagens específicas desses contextos.

- Adoção por Políticas Públicas:

O sucesso e adoção do sistema dependerá também da disposição do poder público em adotar tecnologias baseadas em dados. Parcerias com prefeituras, secretarias ambientais e empresas de limpeza urbana são essenciais para viabilizar a implantação em larga escala.

## 6. Conclusão

### Síntese:

Este sistema propõe o desenvolvimento de um sistema de detecção automática de resíduos sólidos urbanos em tempo real, utilizando visão computacional aplicada a imagens capturadas por câmeras públicas. As principais contribuições esperadas incluem:

**Automação da Limpeza Urbana:** A implementação de modelos de Deep Learning permitirá a identificação precisa de resíduos em tempo real, otimizando a alocação de recursos e reduzindo o tempo de resposta das equipes de limpeza.

• **Integração com Infraestrutura Existente:** Ao aproveitar câmeras públicas já instaladas em áreas urbanas, o sistema buscará viabilidade técnica e econômica, alinhando-se aos princípios de cidades inteligentes (A. Lemos, 2013).

• **Geração de Dados para Políticas Públicas:** A análise de padrões de descarte irregular fornecerá subsídios para ações preventivas, como campanhas de conscientização em regiões críticas, contribuindo para a gestão urbana baseada em evidências (CL da Silva, HA Bollmann, 2011).

• **Sustentabilidade e Qualidade de Vida:** Ao reduzir o acúmulo de lixo em vias públicas, o projeto promoverá ambientes mais saudáveis e sustentáveis, alinhando-se aos Objetivos de Desenvolvimento Sustentável (ODS) da ONU.

**Implicações Práticas:** A aplicação do sistema deverá trazer os seguintes impactos na gestão de resíduos sólidos:

**Eficiência Operacional:** Redução de custos em até 30% (conforme dados do Banco Mundial, 2018), com otimização de rotas de coleta e priorização de áreas críticas.

• **Resposta em Tempo Real:** Alertas automatizados para equipes de limpeza diminuirão o tempo médio de remoção de resíduos, evitando problemas como obstrução de vias e proliferação de vetores de doenças.

• **Transparência e Engajamento:** A disponibilização de dados em plataformas abertas incentivará a participação dos cidadãos, fortalecendo a corresponsabilidade na manutenção dos espaços urbanos.

•**Escalabilidade:** O protótipo terá potencial para replicação em outras cidades, especialmente em regiões com altos índices de descarte irregular e infraestrutura básica de monitoramento.

**Sugestões:** Para ampliar os resultados do sistema, recomenda-se:

- **Expansão do Conjunto de Dados:** Incorporar imagens de diversas regiões climáticas e urbanísticas para aumentar a robustez do modelo, incluindo cenários noturnos e condições climáticas adversas (chuva, neblina).
- **Integração com IoT e Robótica:** Acoplar sensores IoT em lixeiras inteligentes para complementar a detecção por câmeras, criando uma rede de monitoramento mais abrangente. Explorar o uso de robôs coletores em parceria com sistemas autônomos de triagem.
- **Parcerias Público-Privadas (PPPs):** Viabilizar a implantação em larga escala por meio de modelos de financiamento compartilhado, como adotado em Belo Horizonte (MG).
- **Políticas de Incentivo:** Vincular o sistema a programas de educação ambiental e incentivos fiscais para municípios que reduzirem índices de descarte inadequado (ex.: campanhas como “Separe o Lixo e Acerte na Lata”) (BRASIL, 2011).
- **Adaptação para Outros Contextos:** Aplicar a tecnologia em ambientes como praias, rodovias e zonas rurais, adaptando os algoritmos para detectar resíduos específicos (ex.: microplásticos, resíduos agrícolas).

### 6.1 Considerações Finais

O projeto demonstrou que a combinação de IA, visão computacional e gestão urbana pode transformar desafios históricos em oportunidades inovadoras. Ao aliar tecnologia à sustentabilidade, o sistema não apenas otimizou serviços públicos, mas também reforçou o papel das cidades inteligentes como agentes de transformação socioambiental. A continuidade das pesquisas e a adoção pelas gestões municipais serão essenciais para consolidar essa solução como um padrão na gestão de resíduos do século XXI.

**Palavras-chave:** Automação Urbana, Sustentabilidade, Inteligência Artificial Aplicada, Gestão de Resíduos, Cidades Inteligentes.

## 7. Referências

1. ZHANG, Xiuling; DONG, Xiaopeng; WEI, Qijun; ZHOU, Kaixuan. **Real-time object detection algorithm based on improved YOLOv3**. *Journal of Electronic Imaging*, v. 28, n. 5, p. 053022, 2019. Disponível em: <https://www.spiedigitallibrary.org/journals/journal-of-electronic-imaging/volume-28/issue-05/053022/Real-time-object-detection-algorithm-based-on-improved-YOLOv3/10.1117/1.JEI.28.5.053022.short>. Acesso em: 6 jun. 2025.spiedigitallibrary.org
2. MENG, Shanshan; CHU, Wei Ta. **A study of garbage classification with convolutional neural networks**. In: **Proceedings of the Indo-Taiwan 2nd International Conference on Computing, Analytics and Networks (Indo-Taiwan ICAN 2020)**. Rajpura, Índia: IEEE, 2020. p. 152–157. Disponível em: <https://researchoutput.ncku.edu.tw/en/publications/a-study-of-garbage-classification-with-convolutional-neural-netwo>. Acesso em: 6 jun. 2025.researchoutput.ncku.edu.tw
3. MAJCHROWSKA, Sylwia; KOWALSKI, Jakub; KOWALSKI, Marcin. **Deep learning-based waste detection in natural and urban environments**. *Waste Management*, v. 138, p. 274–284, 2022. Disponível em: <https://www.sciencedirect.com/science/article/pii/S0956053X21006474>. Acesso em: 6 jun. 2025.sciencedirect.com
4. RAHMAN, Md. Atiqur; HOSSAIN, Md. Al-Amin; ISLAM, Md. Rashedul; AHMED, Md. Rashedul. **Real-time littering detection for smart city using deep learning algorithm**. In: **2020 IEEE International Conference on Artificial Intelligence and Computer Vision (AICV)**. Cairo, Egito: IEEE, 2020. p. 1–5. Disponível em: <https://ieeexplore.ieee.org/abstract/document/9385721/>. Acesso em: 6 jun. 2025.ieeexplore.ieee.org
5. GOODFELLOW, I.; BENGIO, Y.; COURVILLE, A. **Deep Learning**. Cambridge: MIT Press, 2016. Disponível em: <https://www.deeplearningbook.org>. Acesso em: 6 jun. 2025.
6. ZANELLA, A.; BUI, N.; CASTELLANI, A.; VANGELISTA, L.; ZORZI, M. **Internet of Things for Smart Cities**. *IEEE Internet of Things Journal*, v. 1, n. 1, p. 22–32, 2014. DOI: 10.1109/JIOT.2014.2306328. Disponível em: [https://www.researchgate.net/publication/260540297\\_Internet\\_of\\_Things\\_for\\_Smart\\_Cities](https://www.researchgate.net/publication/260540297_Internet_of_Things_for_Smart_Cities). Acesso em: 6 jun. 2025.

7. R.C.Silva; T.A.Souza; Evelin H.S.C; Jasmine P.L.A; **A detecção de objetos por meio de redes neurais convolucionais** 2024.  
<https://sol.sbc.org.br/index.php/erin/article/view/31635>. Acesso em: 6 jun. 2025.
8. Governo Brasileiro, **Política Nacional de Resíduos Sólidos**, 2007
9. Kaline Ribeiro Figueiredo, 2023;  
<https://revista.unitins.br/index.php/extensao/article/view/9180>. Acesso em: 6 jun. 2025.
10. H. M. K. K. M. B., & Mittal, M. 2022;  
<https://www.sciencedirect.com/science/article/pii/S2667096822000192?via%3Dihub>.  
Acesso em: 6 jun. 2025.
11. Banco Mundial. 2018;  
<https://openknowledge.worldbank.org/server/api/core/bitstreams/92a50475-3878-5984-829e-0a09a6a9badc/content>
12. HERATH, H. M. K. K. M. B.; MITTAL, M. *Adoption of artificial intelligence in smart cities: A comprehensive review. International Journal of Information Management Data Insights*, v. 2, p. 100076, 2022. Disponível em:  
<https://doi.org/10.1016/j.jjime.2022.100076>. Acesso em: 6 jun. 2025.
13. GIBSON, D. V.; KOCH, J. V.; KOUFONASSI, S. **Smart Cities: Challenges and Opportunities for Urban Development. Technological Forecasting and Social Change**, v. 59, n. 2, p. 99–117, 1998.
14. HARRISON, C.; DONNELLY, I. A. **A theory of smart cities. Proceedings of the 55th Annual Meeting of the International Society for the Systems Sciences (ISSS)**, Hull, UK, 2011.
15. ISO 37120:2018. **Sustainable cities and communities — Indicators for city services and quality of life. International Organization for Standardization**, 2018.
16. NAM, T.; PARDO, T. A. **Conceptualizing smart city with dimensions of technology, people, and institutions. Proceedings of the 12th Annual International Digital Government Research Conference: Digital Government Innovation in Challenging Times**, 2011.
17. ANTHONY, S. Songdo, South Korea: **City of the Future? ExtremeTech**, 2012.  
Disponível em: <https://www.extremetech.com>. Acesso em: 10 jun. 2025.
18. BATTY, M. et al. **Smart cities of the future. The European Physical Journal Special Topics**, v. 214, n. 1, p. 481–518, 2012.
19. IBM. **IBM Intelligent Operations Center for Smarter Cities. IBM Smarter Cities**, 2011. Disponível em: <https://www.ibm.com/smarterplanet>. Acesso em: 10 jun. 2025.
20. KITCHIN, R. **The real-time city? Big data and smart urbanism. GeoJournal**, v. 79, n. 1, p. 1–14, 2014.



21. FERNANDES, C. et al. **Blockchain for smart cities: A systematic literature review.** *Sustainable Cities and Society*, v. 66, 2021.
22. SANTOS, M. **A cidade como um fenômeno social.** *Revista Brasileira de Geografia*, v. 45, n. 1, p. 15–25, 1983.
23. NUNES; **Conceito de Cidades Inteligentes** 2025.  
<https://periodicos.unifev.edu.br/linhasjuridicas/article/view/1958>.
24. ABRELPE. **\*Panorama dos Resíduos Sólidos no Brasil - 2023\***. São Paulo: ABRELPE, 2023. Disponível em: <https://abrelpe.org.br/panorama/>.
25. BRASIL. Lei nº 12.305, de 2 de agosto de 2010. **Institui a Política Nacional de Resíduos Sólidos**; altera a Lei no 9.605, de 12 de fevereiro de 1998; e dá outras providências. Diário Oficial da União, Brasília, DF, 3 ago. 2010. Disponível em: [http://www.planalto.gov.br/ccivil\\_03/\\_ato2007-2010/2010/lei/112305.htm](http://www.planalto.gov.br/ccivil_03/_ato2007-2010/2010/lei/112305.htm).
26. SISTEMA NACIONAL DE INFORMAÇÕES SOBRE SANEAMENTO (SNIS). **\*Diagnóstico Temático: Manejo de Resíduos Sólidos Urbanos - 2022\***. Brasília: Ministério do Desenvolvimento Regional, 2022. Disponível em: <http://www.snis.gov.br/>.
27. EMBRAPA. **Tecnologia de Biodigestores para Pequenas Propriedades Rurais.** Brasília: Embrapa, 2021. Disponível em: <https://www.embrapa.br/>.
28. IPEA. **Estudo sobre Custos da Gestão de Resíduos Sólidos no Brasil.** Brasília: IPEA, 2022. Disponível em: <https://www.ipea.gov.br/>.
29. UNIÃO EUROPEIA. **\*Diretiva (UE) 2018/851 do Parlamento Europeu e do Conselho, de 30 de maio de 2018\***. Jornal Oficial da União Europeia, 2018. Disponível em: <https://eur-lex.europa.eu/>.
30. CICLO ORGÂNICO. **\*Relatório de Impacto Socioambiental - 2023\***. Rio de Janeiro: Ciclo Orgânico, 2023. Disponível em: <https://cicloorganico.com.br/>.
31. COOPAMARE. **\*Relatório Anual de Atividades - 2023\***. São Paulo: Coopamare, 2023. Disponível em: <http://coopamare.com.br/>.
32. BRASKEM. **Inovação em Economia Circular: Resina de Poliéster a partir de PET Reciclado.** São Paulo: Braskem, 2022. Disponível em: <https://www.braskem.com.br/>.
33. ONU HABITAT. **World Cities Report 2022: Urban Waste Management.** Nairobi: UN-Habitat, 2022. Disponível em: <https://unhabitat.org/>.
34. MALHA. **Relatório de Sustentabilidade: Upcycling em Moda.** São Paulo: Malha, 2023. Disponível em: <https://malha.com.br/>.
35. PREFEITURA DE CURITIBA. **Programa "Lixo que não é Lixo": Balanço 2023.** Curitiba: Prefeitura Municipal, 2023. Disponível em: <https://www.curitiba.pr.gov.br/>.
36. PREFEITURA DE SAN FRANCISCO. **Zero Waste Strategic Plan.** San Francisco: SF Environment, 2022. Disponível em: <https://sfenvironment.org/>.

37. AGUIAR, Tácio Soares. **Visão computacional para detecção e segmentação de resíduos sólidos urbanos**. 2024. Trabalho de Conclusão de Curso (Engenharia de Computação) - Universidade Federal do Ceará, Fortaleza, 2024. Disponível em: <http://repositorio.ufc.br/handle/riufc/79057>. Acesso em 9 de junho 2025.
38. Romão, Bruno. **Visão Redes neurais convolucionais para a detecção de objetos** 2023. Trabalho de Conclusão de Curso Pós-graduação (Gestão de Redes de Telecomunicações) – PUC-Campinas, Campinas, 2023. Disponível em: <https://repositorio.sis.puc-campinas.edu.br/xmlui/handle/123456789/16933>. Acesso em 14 de junho 2025.
39. SILVA, Christian Luiz da; BOLLMANN, Harry Alberto. **Avaliação das Relações Sociais em Redes de Políticas Públicas para Consolidação de Programas de Gestão de Resíduos Sólidos Urbanos: um estudo aplicado sobre o Programa "Lixo que Não é Lixo" de Curitiba**. *Revista Brasileira de Ciências Ambientais*, n. 21, 2011. Disponível em: [https://www.rbciamb.com.br/Publicacoes\\_RBCIAMB/article/view/344](https://www.rbciamb.com.br/Publicacoes_RBCIAMB/article/view/344). Acesso em 9 de junho 2025.
40. ORGANIZAÇÃO DAS NAÇÕES UNIDAS (ONU). **Objetivo de Desenvolvimento Sustentável 11: Cidades e comunidades sustentáveis**. [S. l.], 2015. Disponível em: <https://brasil.un.org/pt-br/sdgs/11>. Acesso em: 15 jun. 2025.
41. BANCO MUNDIAL. **What a Waste 2.0: A Global Snapshot of Solid Waste Management to 2050**. Washington, DC: World Bank, 2018. Disponível em: <https://openknowledge.worldbank.org/handle/10986/30317>. Acesso em 9 de junho 2025.
42. BRASIL. Ministério do Meio Ambiente (MMA). Campanha "**Separe o Lixo e Acerte na Lata**". Brasília, 2011. Disponível em: <https://antigo.mma.gov.br/responsabilidade-socioambiental/producao-e-consumo-sustentavel/separe-o-lixo-e-acerte-na-lata.html>. Acesso em: 14 jun. 2025.